Отчет о проделанной работе

Тема: Сравнение методов моделирования сезонности временных рядов

Участники: Терехин Кирилл Вячеславович, Еремина Елена Дмитриевна

Постановка задачи

Цель работы - выяснить, какие способы задания сезонности лучше работают в глобальной табличной модели для почасовых временных рядов.

Мы сравнивали несколько вариантов признаков для CatBoost: только обычные лаги, лаги с сезонными лагами, лаги с календарными признаками, лаги с фурье-признаками и их комбинации. Также мы хотели проверить, зависит ли эффект от силы сезонности ряда и от горизонта прогнозирования.

Основная гипотеза заключалась в том, что явное добавление сезонной информации в признаки должно улучшать качество прогноза по сравнению с моделью только на обычных лагах. Кроме того, ожидалось, что этот эффект будет сильнее на рядах с более выраженной сезонностью и на более дальних шагах прогноза.

Распределение ролей

Терехин Кирилл Вячеславович:

- реализациея основного пайплайна эксперимента;
- обучение моделей CatBoost;
- сбор результатов.

Еремина Елена Дмитриевна:

- предварительный анализ данных;
- исследование сезонности;
- запуск и анализ baseline-моделей;
- подготовка визуализаций и отчета.

Постановка задачи, обсуждене результатов и формулировка выводов выполнялись совместно.

Описание данных

В работе использовался датасет Electricity Hourly Dataset из Monash Time Series Forecasting Repository.

Датасет содержит почасовые временные ряды потребления электроэнергии. По графикам и по функции автокорреляции в данных хорошо видна сезонность. Наиболее выраженными оказались два периода: 24 часа и 168 часов, то есть суточная и недельная сезонности.

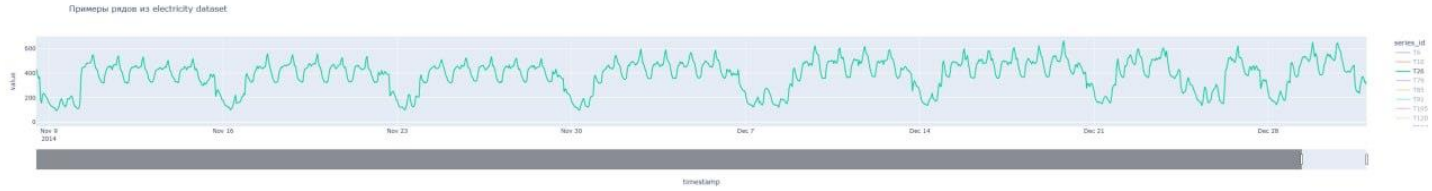

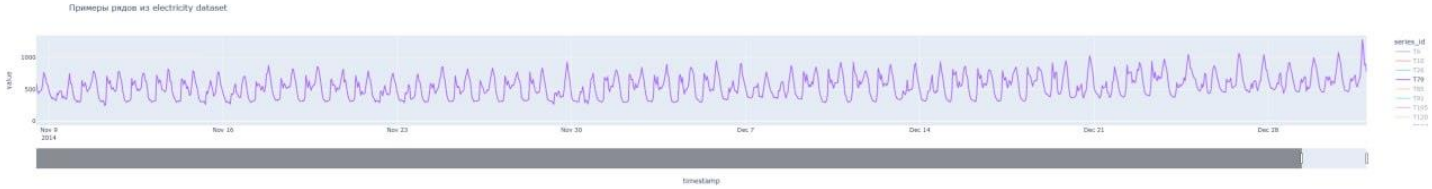

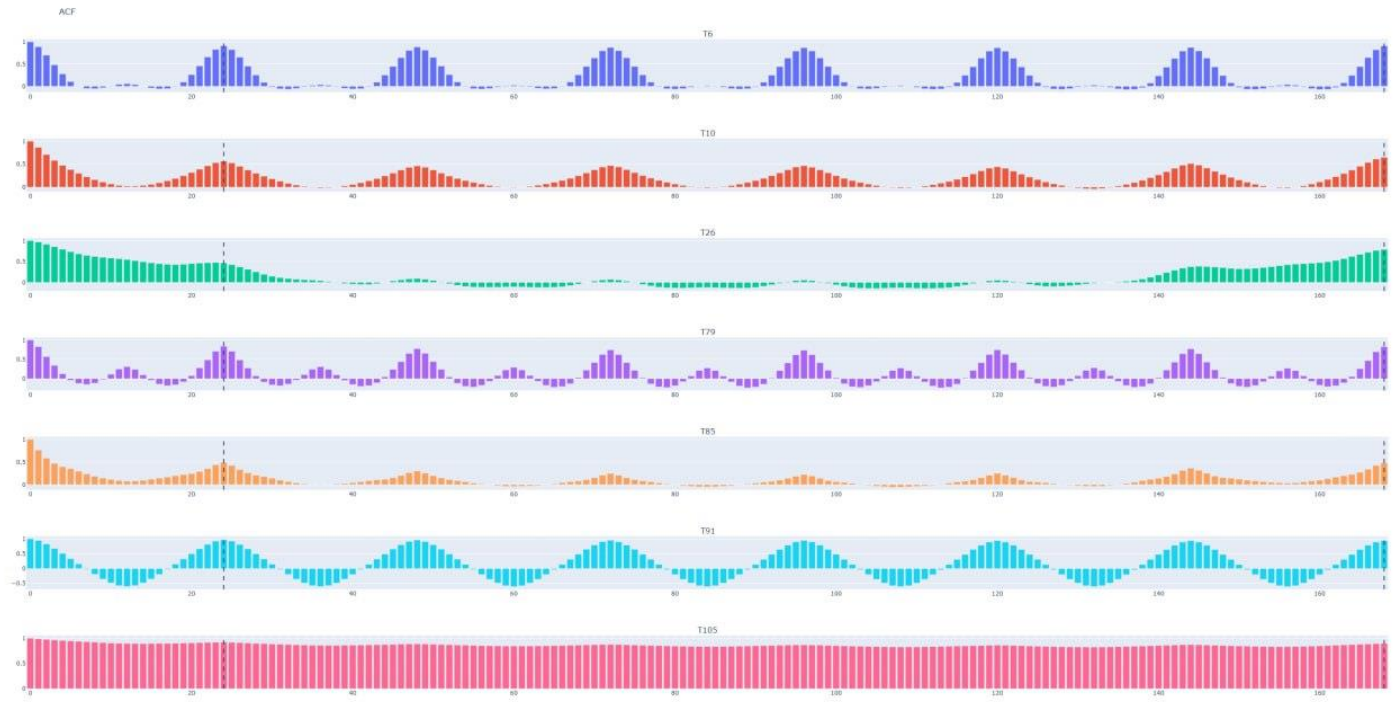

По ACF видно, что у большинства выраженная суточная сезонность: регулярные пики на лагах, кратных 24. У части рядов (например, T6, T79 и T91). У T6 и T91 эта структура наблюдается постоянно, что указывает на повторение дневного паттерна. У T79 суточная сезонность тоже хорошо выражена, но между положительными пиками ACF уходит в отрицательную область, структура выглядит более волнообразной.У рядов T10 и T85 суточная сезонность также сохраняется, однако выражена слабее: пики на лагах 24, 48, 72 и далее присутствуют, но их амплитуда ниже, а сама форма ACF более сглаженная.

Сильно отличаются T105 и T26. Для T105 ACF остается высокой почти на всех лагах, поэтому здесь доминирует не столько чистая сезонность, сколько сильная общая автокоррелированность ряда. У T26 после начального участка ACF уходит к низким или отрицательным значениям, а затем снова возрастает к лагу 168, что согласуется с недельной сезонностью. При этом суточная сезонность у них тоже присутствует, но она выражена менее чисто, чем у остальных рядов.
В целом график подтверждает, что для датасета типична суточная сезонность, а у части рядов поверх нее дополнительно проявляется недельная.

Для основного эксперимента ряды были дополнительно разделены по силе недельной сезонности. Для этого на обучающей части каждого ряда рассчитывался показатель acf_168, после чего ряды разбивались на три группы: weak, medium и strong. Из каждой группы случайно отбиралось по 20 рядов. Таким образом, в основном эксперименте использовалось 60 временных рядов.

Методология эксперимента

Все модели сравнивались на одном и том же временном разбиении. Для каждого ряда применялось фиксированное окно: обучение - 12 недель, тест - 1 неделя.

Для CatBoost были протестированы следующие наборы признаков:

- только обычные лаги;
- лаги и сезонные лаги;
- лаги и календарные признаки;
- лаги и фурье-признаки;
- лаги, сезонные лаги и календарные признаки;
- лаги, сезонные лаги и фурье-признаки;
- лаги, сезонные лаги, календарные и фурье-признаки.

В признаках использовались:

- обычные лаги;
- сезонные лаги 24 и 168;
- календарные признаки: час, день недели, месяц;
- фурье-признаки для периодов 24 и 168.

Качество моделей оценивалось:

- по всем рядам вместе;
- отдельно по группам weak, medium и strong;

Для оценки использовались метрики MAE, sMAPE, MASE24 и MASE168. MAE показывает абсолютную ошибку, sMAPE — относительную ошибку в процентах, а MASE24 и MASE168 позволяют сравнить модели с сезонным наивным ориентиром для суточной и недельной сезонности.

Описание моделей

В качестве baseline-моделей использовались:

- Naive;
- SeasonalNaive_24;
- SeasonalNaive_168;
- AutoETS_24;
- AutoETS_168;
- AutoTheta_24;
- AutoTheta_168.

В качестве основной глобальной модели использовался CatBoostRegressor.

Для CatBoost применялась блочная direct-стратегия прогнозирования. Весь горизонт 168 часов делился на 7 блоков по 24 часа. Для каждого блока обучалась отдельная модель, после чего прогнозы объединялись в один недельный прогноз.

Результаты

Среди baseline-моделей лучший результат показала SeasonalNaive_168. Для нее были получены значения MASE168 = 1.5833 и sMAPE = 17.13. Это показывает, что недельная структура в данных очень стабильна, и прогноз по значениям прошлой недели работает очень хорошо.

	model	mae	smape	mase24	mase168
0	SeasonalNaive_168	192.054067	17.133718	1.726338	1.583300
1	AutoETS_168	266.585463	22.342965	2.201268	1.971572
2	AutoETS_24	255.601276	24.266528	2.253166	2.119232
3	SeasonalNaive_24	292.823710	23.370962	2.427086	2.211603
4	CB_Lags_Seasonal_Calendar_Fourier	262.891114	28.692684	3.279218	2.495211
5	CB_Lags_Seasonal	280.216868	29.616412	3.181215	2.509631
6	CB_Lags_Seasonal_Fourier	269.965885	28.872100	3.302886	2.515417
7	CB_Lags_Fourier	274.371767	29.222872	3.288277	2.535506
8	CB_Lags	291.404134	30.254752	3.291742	2.567963
9	CB_Lags_Seasonal_Calendar	281.597399	30.854821	3.541883	2.688141
10	CB_Lags_Calendar	295.432244	30.798495	3.439818	2.688678
11	AutoTheta_168	388.520235	35.471902	3.431309	2.984648
12	AutoTheta_24	387.809335	36.139218	3.473009	3.020403
13	Naive	562.182837	45.793198	4.920512	4.426650

Naive-модель, не учитывающая сезонность, показала худший результат, что подтверждает важность сезонной структуры в этих данных.

Внутри семейства CatBoost все модели, в которых сезонность задавалась явно, показали лучшее качество по сравнению с вариантом только на обычных лагах. Наиболее сильные результаты дали конфигурации с сезонными лагами и фурье-признаками, а также их комбинации с календарными признаками.

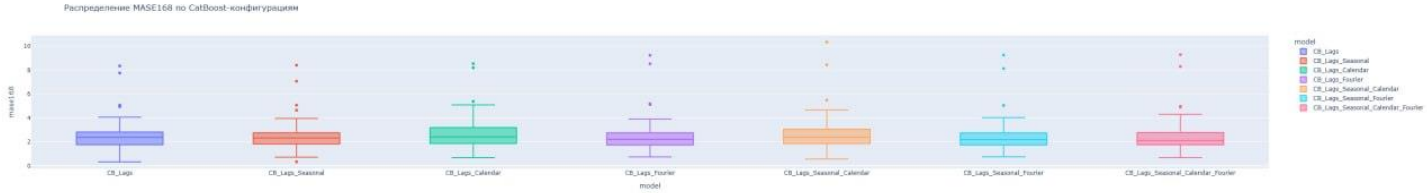

При этом ни одна из конфигураций CatBoost не смогла превзойти SeasonalNaive_168.

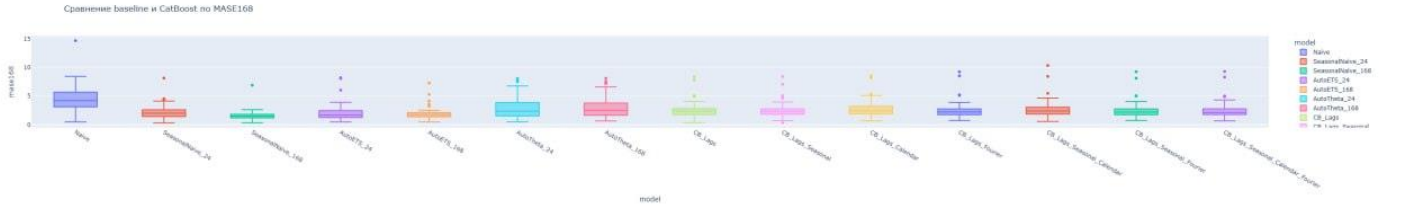

Анализ по группам показал, что на рядах с более сильной сезонностью, то есть в группах medium и strong, выигрыш от сезонных признаков был заметнее, чем в группе weak.

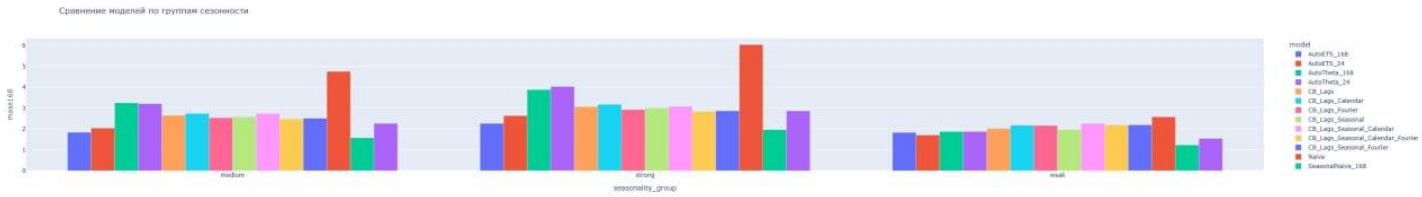

Выводы

- В работе было показано, что данные действительно содержат выраженную суточную и недельную сезонность.
- Лучшей baseline-моделью оказалась SeasonalNaive_168, что связано с высокой стабильностью недельного паттерна.
- Для CatBoost явное добавление сезонной информации оказалось полезным: модели с сезонными лагами, календарными и фурье-признаками стабильно работали лучше, чем модель только на обычных лагах.
- Наиболее полезными оказались сезонные лаги и фуре-признаки, особенно на рядах с более выраженной сезонностью.

Итоговый вывод состоит в том, что для глобальной табличной модели сезонность лучше задавать явно — через сезонные лаги, календарные и фурье-признаки. Однако в данной постановке самым сильным ориентиром остался SeasonalNaive_168.